2023 AI · DS Capstone

MLB's on-base and out prediction model by pitcher and batter type using machine learning

안동수 . 김지민 . 손주찬



Research History





Contents

Chapter 1. Introduction

Chapter 2. Model Development

Chapter 3. Conclusion and Application



Chapter 1

Introduction



Limitations of Previous Studies

1. Unable to reflect the complex situation of the game 타입 > hit-into-play 된 타구 ▷ 안타 : 1루타(single), 2루타(double), 3루타(triple) 중 안타와 홈런만 측정 ▷ 홈런(homerun) 예측결과 명목 ▷ 직구: 패스트볼(4심), 싱커(2심), 커터, 컷패스트볼 ▷ 변화구: 슬라이더, 커브, 너클커브, 슬로우커브, 너클, 이퍼스, 슬로브, 구종 pitch_type ▷ 오프스피드: 스플릿핑거, 체인지업, 포크볼, 스크류볼 예측을 투구속도 단위: 마일(mph) release_speed 위한 명목 투입변수 투구존 1번~14번 타자위치 좌타 / 우타 명목 독립 명목 투수주손 좌완 / 우완 p_throws 볼카운트 이산 strikes 스트라이크카운트 0~2 〈투구존〉

Excluding various variables that could affect the outcome of the pitch

The situation to predict is fragmented as it is limited to the hitting situation

Limitation of not capturing the complexity of baseball,

where a single change in a small variable can lead to a variable of situations

2. Overlooking the Impact Player-Specific Characteristics

				구 질								
			직구	커브	슬라이더	체인지업	싱커	전체				
	s ·	빈도	479	241	0	187	5	912				
선	٠ د	전체%	31.6%	1.8%	0%	7.1%	0.2%	34.5%				
수	р.	빈도	834	47	725	123	0	1729				
	r	전체%	31.6%	1.8%	27.5%	4.7%	0%	65.5%				
전체		빈도	1313	288	725	310	5	2641				
~인/	۱ ال	전체%	49.7%	10.9%	27.5%	11.7%	0.2%	100.0%				

Various types of pitchers depending on the player's style

Matchups may differ based on player types within positions, influencing strategic approaches


Previous research has not adequately considered variables stemming from player characteristics



그는 그는 그. 1). 조선미, 김주학, 강지연, 김상균. "머신러닝(XGBoost)기반 미국프로야구(MLB)의 투구별 안타 및 홈런 예측 모델 개발." 한국체육측정평가학회지, vol. 25, no. 1, 2023, pp. 65-76. 2). 손혁. "프로야구 투수유형과 구질과의 관계." 국내석사학위논문 고려대학교 교육대학원, 2004. 서울

^{3).} 황수웅. 불확실성(uncertainty)을 고려한 스포츠 빅데이터 분석: Bayesian 추정과 Deep Learning을 활용한 프로야구 심판의 Ball/Strike 판정 평가 모델 개발. 서울대학교 대학원. 2023

Research Novelty



<u>기존 변수</u>

<u>신규 변수</u>

공의 상하 움직임 투구 폼 투수 익스텐션 투수 릴리스 포인트 주자 여부 점수, 이닝 아웃카운트

Consider the factors
that can affect pitching results
in more ways than previous

Predictions on multiple Scenarios

<u>기존 연구</u>

타격 결과 (안타, **흘**런) 투구 결과 (스트라이크, 볼)

not a comparable result

Predict the number of cases


in the same situation

<u>본 연구</u>

출루 (안타, 홈런, 볼넷) + 아웃 (삼진, 뜬공, 병살...)

Predictions including various situations that may occur in baseball

Factors influencing outcomes for different player types



Considering the characteristics of each player's type and the variables of the characteristics caused by this type

Research Importance

Importance of identifying on-base/out indicators

Base	Run	ners	20	010-201	.5		1	993-200	9	1969-1992			1950-1968				
1B	2B	3B	0 outs	1 outs	2 outs		0 outs	1 outs	2 outs		0 outs	1 outs	2 outs		0 outs	1 outs	2 outs
_			0.481	0.254	0.098		0.547	0.293	0.113		0.477	0.252	0.094		0.476	0.256	0.098
1B			0.859	0.509	0.224		0.944	0.565	0.245		0.853	0.504	0.216		0.837	0.507	0.216
_	2B	_	1.100	0.664	0.319	Г	1.175	0.723	0.349	П	1.102	0.678	0.325	Г	1.094	0.680	0.330
1B	2B	_	1.437	0.884	0.429		1.562	0.966	0.471		1.476	0.902	0.435		1.472	0.927	0.441
_	_	3B	1.350	0.950	0.353		1.442	0.991	0.388		1.340	0.943	0.373		1.342	0.926	0.378
1B		3B	1.784	1.130	0.478		1.854	1.216	0.533		1.715	1.149	0.484		1.696	1.151	0.504
_	2B	3B	1.964	1.376	0.580		2.053	1.449	0.626		1.967	1.380	0.594		1.977	1.385	0.620
1B	2B	3B	2.292	1.541	0.752	Г	2.390	1.635	0.815	П	2.343	1.545	0.752	Г	2.315	1.540	0.747

□□: http://www.tangotiger.net/re24.html

• 해당 주루/아웃 상태에서 해당 이닝이 끝날 때까지 득점할 확률

Differences in scoring probability depending on the presence or absence of runners in the same out situation

I → Identify the indicators of out and on-baseI = Factors that directly lead to victory or defeat

Create a strategy based on data




□ □: https://www.gqkorea.co.kr/2020/03/05/

If knowing the type and type of player,
rational decisions can be made in establishing
strategies such as batter placement and pitcher
replacement strategies



/ Model development plan



- Step 1. Data Collection
- Step 2. Data Preprocessing
- Step 3. Creation of New Independent Variables using K-means
- Step 4. Data Integration
- Step 5. Variable Scaling & Oversampling
- Step 6. On-Base Percentage Variable Generation
- Step 7. Train Set & Test Set Creation
- Step 8. Model Training



Chapter 2.

Model Development



✓ Step 1. Data Collection

Collection of pitch-related data from Major League Baseball's official record website "MLB Savant."





출처: https://baseballsavant.mlb.com/

List of data collected (2020-2022) → 421,879 rows

1. Dependent Variables:

- On-Base / Out

2. Independent Variables:

- Strike, Ball
- Pitch Velocity, Pitch Type
- Vertical and Horizontal Ball Movement
- Pitching Form, Pitcher Extension, Pitch Release Point
- Game Situation at the Time of Pitching

(Presence of Runners, Game Score, Inning, Out Count)



Step 2. Data Preprocessing

1). Removing Outliers

predict the on-base between normal positions (pitcher vs. hitter)

→ Excluding cases where a batter takes

the mound as a pitcher as an outlier

- · Criteria for judging the batter's mound.
- MLB Pitcher Lowest Pitcher Under 69.9 Mile In 2022
- 2021 MLB Pitcher Lowest Pitcher Under 64.7 Mile
- 2020 MLB Pitcher Lowest Pitcher Less Than 65 Mile
- The above balls are judged to have been thrown by the other
- → Delete pitches below the minimum pitcher's ball speed by year as

outliers

2). Removing Missing Value

The percentage of missing values in all variables is 0.3% or

less

→ Decide that there will be no impact on the model,

Remove all missing values

- release_pos_x
- 0.013823 0.013823
- release_pos_z
- 0.001728
- pfx_x
- 0.001728
- pfx_z
- 0.000494
- release_spin_rate
- 0.328060 0.140209
- release_extension
- release_pos_y
- 0.013823

결측치 비율 (%)

- spin axis
- 0.328060

3). Preprocessing categorical data

Mapping to number the categorical data

- Pitcher Handedness: Right-handed/Left-handed \rightarrow 1 / 2
- Batter Handedness: Right-handed/Left-handed → 1 / 2
- Pitch Type: Fastball → 1, Offspeed → 2, Breaking Ball →
 3
- On-Base: Hit, Home Run, Walk, Hit by Pitch → 1
- Out: Double Play, Triple Play, Flyout, Groundout → 0

Pitch_type	Release_speed	On_1b	 release_pos_x	release_pos_y	events
3	90.0	0	 -2.20	6.49	1
1	95.2	0	 -2.33	6.41	0
1	92.2	1	 -2.13	6.48	0
3	83.7	0	 -2.28	6.33	0


ANG GLOBAL UNITED STATE OF THE STATE OF THE

✓ Step 3. Generate new variables using K-means clustering on a per-player basis


1). Grouping by players' performance

- 1. Using average performance data for pitchers and batters for 2020 to 2022
- Batters: strikeout rate, walk on base rate, home run, ops, quality of batting
- Pitcher: Fastball and breaking ball restraint, hit rate, ERA
- 2.. Selection of the number of clusters using the "Elbow Method"
- 5 batters
- 6 pitchers

3. Clustering



Selection of the number of batter clusters



Selection of the number of Pitcher Clusters



^{1).} 한국프로야구에서 타자능력의 측정 (이장택, 2014)



^{2).} Investigating Major League Baseball Pitchers and Quality of Contact through Cluster Analysis" (Marcou, 2020)

✓ Step 3. Generate new variables using K-means clustering on a per-player basis

- 2). Check the characteristic of cluster
 - characteristic of batter cluster

군집	키워드	대표 선수	홈런	삼진율	볼넷율	타율	출루율	장타율	OPS	Babip	Pull Percent	Line drive percent
1번	당겨치기, 낮은 타율, 높은 볼넷 출루율	최지만	7.06	27.9%	9.1%	0.220	0.300	0.398	0.698	0.276	42.49%	23.2%
2번	전반적 낮은 수치	쓰쓰고 요시토모	2.46	26.3%	7.5%	0.195	0.264	0.291	0.556	0.255	37.22%	22.0%
3번	낮은 삼진율 높은 라인드라이브 타율	김하성	6.66	20.3%	7.4%	0.255	0.318	0.386	0.704	0.306	38.71%	25.0%
4번	높은 타율, 타점, 홈런 핵심 타자	오타니 쇼헤이	18.6	22.3%	9.6%	0.258	0.337	0.467	0.804	0.297	39.29%	23.98%
5번	메이저리그 적응 실패, 매우 낮은 성적	린즈웨이	0.148	45.27%	3.4%	0.114	0.149	0.146	0.296	0.235	23.82%	15.7%

• characteristic of pitcher cluster

군집	키워드	대표 선수	직구 구속	변화구 구속	삼진율	볼넷 허용률	방어율	허용타구 속도	포심 구사율	싱커 구사율	슬라이더 구사율	직구 구사율	땅볼유도
1번	싱커 구사, 땅볼 유도형	펠릭스 페냐	93	83	20%	8.9%	4.36	88,2	12.6	45.8	24.5	59.3	51.4
2번	빠른 포심, 탈삼진 능력	맥스 슈어저	94.3	84.2	24.6%	9.6%	4.15	88,8	51.3	9.1	22.6	56.6	39.9
3 번	낮은 구속, 정교한 제구력	류현진	90.3	78.8	21.1%	8.2%	4.38	88,1	26.2	20.9	9.9	69.8	42.8
4번	메이저리그 경력 적지만 방어율 높음	조던 야마모토	91.9	81.3	18%	9.9%	7.51	90,3	43.4	14.1	21.5	56.7	36.3
5번	마무리 투수, 높은 삼진율	에드윈 디아즈	93.7	84.2	25.5%	9.5%	3.95	88,3	34.6	13.1	46.5	43.7	43.2
6번	다양한 구종, 선발급 능력	오타니 쇼헤이	92.9	80.4	24.4%	9.1%	4.13	88,5	45.1	11.6	14.8	55.5	41.7



✓ Step 3. Generate new variables using K-means clustering on a per-player basis

2). Check the characteristic of cluster


Characteristics by Batter Cluster



선구안이 좋은 타자그룹

- 낮은 타율(0.220)
- 높은 볼넷율(9.1%)
- 높은 출루율(0.300)

볼을 잘 골라내는 능력을 가졌고 출루율이 높은 타자 그룹 Ex). 최지만 선수



컨택트형 타자 그룹

- 평균 이상의 타율(0.255)
- 낮은 삼진율 (20.3%)
- 높은 라인드라이브 타구율 (25%)

볼 컨택이 좋기 때문에 좋은 타구질을 만들어내는 타자 Ex) 김하성 선숙류



홈런형 파워타자 그룹

- 높은 타율 (0.258)
- 높은 타점 (58)
- 높은 홈런 수 (59)

팀내 중심타선을 담당할 정도의 파워를 가진 4번타자형 타입 Ex) 오타니 쇼헤이 선수



Step 3. Generate new variables using K-means clustering on a per-player basis

- 2). Check the characteristic of cluster
- Characteristics by Pitcher Cluster



땅볼 유도형 투수그룹

- 메이저리그 평균 구속(93마일)
- 땅볼 유도 구종인 싱커의 높은 구사율 (45.8%)
- 높은 땅볼유도 비율 (51.4%)
- → 싱커를 주로 구사하는 땅볼유도형

Ex) "땅볼 유도형" 펠릭스 페냐 선수



직구 위주 삼진형 투수그룹

- 높은 포심 구사율 (51%)
- 높은 삼진율 (24.6%)
- 가장 빠른 직구구속(94.3마일)

ᄗ ["]ᆀᄋᅾᆔᇎᆋᇹᇦᇴᆋᆂᄛ ᄜᄼᅲᇝ



제구형 투수그룹

- 낮은 직구속도(90마일)
- 낮은 변화구 속도(78마일)
- 낮은 볼넷 허용률(8.2%)
- → 변화구와 직구 사이에 큰 속도편차를 활용하고 정교한 제구력으로 승부 Ex) "칼제구" 류현진 선수



직구, 슬라이더 등 구위가 좋은 삼진형 투수그룹

- 적은 평균 이닝 소화(39.5이닝)
- 가장 높은 삼진율 (25.5%),
- 가장 낮은 방어율 (3.95),
- 낮은 빠른 타구 허용률 (36.8%)
- 직구 구사율 (43%)
- 슬라이더 구사율(46.5%)

EX**文**"철료미후라이테를 좐력아즈 구사하는

마무리 투수 타입



다양한 구종을 구사하는 에이스 선발투수그룹

- 낮은 방어율(4.13)
- 많은 평균이닝(63이닝)
- 삼진율 24%
- 모든 구종 구사비율 최소 10%이상
- → 다양한 구종을 던지는 에이스 선발 투수

Ex) "MVP" 오타니 쇼헤이

✓ Step 3. Generate new variables using K-means clustering on a per-player basis

3). Create cluster variables

Player_id	p_formatted_ip	k_percent	bb_percent	 Pitcher_cluster_label
424144	18.0	19.4	8.3	 0
425794	154.1	19.8	6.1	 2
425844	125.0	18.0	4.3	 5
429722	65.1	18.8	7.	 4

Identify the player's unique number for each cluster and assign a variable



/ Step 4. Data merging

Pitch_type	Release_speed	On_1b	 Batter	Pitcher
2	84.6	1	 542303	601713
2	84.7	1	 518692	601713
1	91.7	1	 645277	601713
1	90.6	0	 542225	601713

After Standard Scaler

0.00 0.25 0.50 0.75 1.00


				_	1
Player_id	p_formatted_ip	k_percent	bb_percent		Pitcher_cluster_label
424144	18.0	19.4	8.3		0
425794	154.1	19.8	6.1		2
425844	125.0	18.0	4.3		5
429722	65.1	18.8	7.		4

Add a cluster number corresponding to the unique identifiers of the Batter and Pitcher variables in the original data and matching rows in the performance data's Player_id.

/ Step 5. Data Scaling

0.200

0.175



Before Scaling

Different variables have different data scales, requiring adjustment for more accurate predictions




Using the standard scaler of the scikit-learn library to scale properties to zero and variance to one



Step 6. Smote Oversampling

- Using the Smote Oversampling technique to solve the unbalance issues in dependent



Step 7. Create on-base rate variables between player types

Calculate the ratio of on-base and out through the results of each cluster of pitchers and batters

Create on-base percentage calculation results in a new column called 'On_base_ratio' and use them as variables for prediction


On-base percentage = (on-base)/(number of showdowns between pitcher and batter)

 \rightarrow Ex) P1 (pitcher cluster 1) vs B1 (baseball cluster 1) = 100 (on-base)/100 (on-base) + 300 (out) = 0.25

Step 8. Model Training

	항목		내용				
	n_estimators	300	트리개수				
주요	num_leaves	65	트리의 리프 노드 개수				
모델	max_depth	13	트리의 최대 깊이				
파라	learning_rate	0.1	학습률				
미터	colsample_bytree	0.5	트리별 특성 샘플링 비율				
-1-1	reg_alpha	0	L1 정규화 파라미터				
	reg_lambda	0	L2 정규화 파라미터				
학습	subsample	0.5	전체 데이터 사용				
태스크	학습비	8:2	모델 학습과 테스트				

- No overfitting due to oversampling
- Adjust hyperparameters to randomsearch cv





^{1).} Football Matches Outcomes Prediction Based on Gradient Boosting Algorithms and Football Rating System(Razali, 2021) 2). 머신러닝을 활용한 빅데이터 분석을 통해 KBO 타자의 OPS 예측(한정섭, 2022)



Chapter 3.

Conclusion and Application



1. Identify team resources, recruit players, plan strategies.





· Understand player types and their compatibility

- 1. Collecting power information on what types of players are in the team
- 2. Understand what types of players your team is struggling against with its current strength.
- → Player type information helps guide team resources and deployment strategies

Use data to identify rookie pitcher types

- ✓ Analyzing 2023 MLB Rookie Pitching with the results
- Senga Kodai → Pitcher cluster 5(Power pitcher type)
- Analyze the characteristics of pitchers in cluster 5 (e.g., Edwin Diaz) to prepare for a rookie matchup.
- → Understand the types of rookies and prepare for the matchup



2. On-base percentage by player type

1. 땅볼 유도형 투수 vs 파워형 타자:

상대적으로 땅볼 투수형은 컨택트형 타자에 강하고, 파워형 타자 그룹에 약 한 면모

(컨택트형 타자에게 출루 허용 → 0.409 / 파워형 타자에게 출루 허용 → 0.458)

2. 마무리 투수 vs 파워형 타자:

상대적으로 마무리 투수형은 컨택트형 타자에 강하고 파워형 타자 그룹에 약 한 면모

(컨택트형 타자에게 출루 허용 → 0.413 / 파워형 타자에게 출루 허용 → 0.485)

- 3. 다양한 구종 구사 가능한 투수
- 선구안형 타자에게 강한 면모: 0.362
- 홈런형 파워 타자에게 강한 면모: 0.372
- 컨택트형 타자에 약한 면모: 0.415



다양한 구종 구사 투수 오타니 쇼헤이



"컨택트형 타자" 김하성



"땅볼 유도형" 펠릭스 페냐



VS

VS

"홈런형 파워타자" 오타니 쇼헤이



"마무리 투수" 에드윈 디아즈



"홈런형 파워타자" 오타니 쇼헤이



"선구안형 타자" 최지만



"홈런형 파워타자" 오타니 쇼헤이



3. Player-specific analytics

Clayton Kershaw



Analysis insights



• Input : 2020-2022 Kershaw's pitching data + cluster

- Leadoff hitter type: 0.232

- Contact hitter type: 0.267

- Slugger type: 0.157

- → Strong against sluggers, but relatively weak against contact batters
- → The need to have a pitching strategy to deal with contact hitters



4. Match lineup preparation strategies



Utilization Plan

- 1. Select an opponent's projected lineup
- 2. Enter starting pitcher pitching information and pitcher type and batter type
- 3. Predicting hit results
- 4. Prepare a preliminary strategy for each opponent
- → Prepare pitch locations and pitch types for each batter with models





5. References for new research



Presents research using a new methodology to predict on-base percentage with pitching

history, pitcher and batter clusters

→ Could become a new reference point for sports research



References

- 1. 김혁주. "한국 프로야구에서 출루 능력과 장타력이 득점 생산성에 미치는 영향," 한국데이터정보과학회지, vol. 23, no. 6, pp. 1165-1174, 2012.
- 2. 박태신, 김재윤. "머신러닝을 활용한 KBO 외국인 투수 재계약 예측 모형," 한국데이터정보과학회지, vol. 33, no. 6, pp. 963-976, 2022, doi: 10.7465/jkdi.2022.33.6.963.
- 3. 손혁. "프로야구 투수유형과 구질과의 관계," 국내석사학위논문 고려대학교 교육대학원, 2004. 서울
- 4. 이장택. "한국프로야구에서 타자능력의 측정," 한국데이터정보과학회지, 25(2), 349-356, 2014.
- 5. 이승훈, 최형준. "미국 프로야구(MLB) 풀카운트 상황에서 투수의 구질, 구속 변화에 따른 투구 결과 분석," 한국체육과학회지, vol. 28, no. 3, pp. 973-981, 2019, doi: 1 0.35159/kjss.2019.06.28.3.973.
- 6. 조선미, 김주학, 강지연, 김상균. "머신러닝(XGBoost)기반 미국프로야구(MLB)의 투구별 안타 및 홈런 예측 모델 개발," 한국체육측정평가학회지, vol. 25, no. 1, 2023, pp. 65-76.
- 7. 조형석. "MLB 타자들의 스윙존에 따른 스윙선택 성향 분석," 국내석사학위논문 명지대학교 기록정보과학전문대학원, 2021.
- 8. 최영환. "4차 산업혁명형 ICT기술이 스포츠 분야에 미치는 기술·문화적 동향분석," 한국스포츠학회 16, no.3 (2018): 1-12.
- 9. 황수웅. "불확실성(uncertainty)을 고려한 스포츠 빅데이터 분석: Bayesian 추정과 Deep Learning을 활용한 프로야구 심판의 Ball/Strike 판정 평가 모델 개발," 서울대학교 대학원, 2023.
- 10. Albert, Jim. 'Beyond Runs Expectancy'. 1 Jan. 2015: 3 18.
- 11. Marcou, Charlie. "Investigating Major League Baseball Pitchers and Quality of Contact through Cluster Analysis" (2020). Honors Projects. 765.
- 12. Nathan, Alan M. "What new technologies are teaching us about the game of baseball." Proceedings of the Euromech Physics of Sports Conference. 2012.
- 13. Otremba Jr., Stephen Eugen. "SmartPitch: Applied Machine Learning for Professional Baseball Pitching Strategy." Massachusetts Institute of Technology, degree of Master of Engineering in Electrical Engineering and Computer Science, 2022. Available at https://hdl.handle.net/1721.1/145144.



THANK YOU

